

《新媒体数据运营与分析》

Excel (7): 统计分析-卡方检验

教师: 林志良

邮箱: linzhl@nfu.edu.cn

个人网站: www.zhilianglin.com

目录

- 卡方检验介绍
 - 列联表
 - 假设检验过程
- 例题
- 软件操作

卡方检验介绍

- **作用：**确定两个分类型变量的关系
 - 例如：
 - 大学生**性别**（男/女）与**学生干部**（干部/非干部）的关系。
 - **专业类型**（人文社科/理工科）与**考公**（考/不考）的关系。
 - **政治身份**（党员/民主党派/团员/群众）与**对某政策的态度**（支持/反对）。

卡方检验介绍

列联表

- 为了分析两个类别型变量之间的关系，我们常常先将数据整理成列联表（contingency table）的形式。
- 列联表是将两个以上的变量进行交叉分类的频数分布表。

卡方检验介绍

列联表

例如，为了研究性别和使用电脑系统的关系，将调查样本（n=300）按性别和电脑系统类型构建列联表。

性别与电脑类型的列联表

性别	电脑类型	
	Mac	Windows
女性	12	108
男性	24	156

卡方检验介绍

观察频数

列联表中的单元格中的数值我们称之为**观察频数** (**observed frequency**)

性别	电脑类型	
	Mac	Windows
女性	12	108
男性	24	156

卡方检验介绍

期望频数

$$f_e = \frac{RT \times CT}{n}$$

其中，

f_e = 给定单元格的期望频数

RT = 给定单元所在的列 (Row) 总和 (Total)

CT = 给定单元所在的行 (Column) 总和 (Total)

n = 样本量

卡方检验介绍

观察频数 vs. 期望频数

其中一个期望
频数的计算：

$$f_e = \frac{RT \times CT}{n}$$
$$= \frac{36 \times 120}{300} = 14.4$$

性别	电脑类型		
	Mac	Windows	
女性	观察频数 = 12 期望频数 = 14.4	观察频数 = 108 期望频数 = 105.6	
男性	观察频数 = 24 期望频数 = 21.6	观察频数 = 156 期望频数 = 158.4	
	36	264	300
	RT (列总和)		n (样本量)
	CT (行总和)		120
	180		180

卡方检验介绍

期望频数的含义

期望频数的含义为假设两分类变量没有关系，列联表中的频数的理论分布状况（理论频数）。

例如，上例中我们的样本量为300。其中，使用Windows的人数为264，占比88%；使用Mac的人数为36，占比12%。样本中有女生120人，男生180人。**如果我们知道性别和使用电脑系统没有关系……**

- **使用Windows和Mac系统的女生的人数应该分别是多少？**

使用Windows的女生人数： $120 \times 88\% = 105.6$ ；使用Mac的女生人数： $120 \times 12\% = 14.4$

- **使用Windows和Mac系统的男生的人数应该分别是多少？**

使用Windows的男生人数： $264 \times 88\% = 158.4$ ；使用Mac的男生人数： $264 \times 12\% = 21.6$



卡方检验介绍

$$\chi^2 = \sum \frac{(f_o - f_e)^2}{f_e}$$

其中，


f_o = 观察频数

f_e = 期望频数

卡方检验的自由度为 $df = (R-1)(C-1)$ ， R和C分别是两个分类型变量的类别量

卡方检验介绍

卡方分布



卡方检验介绍


H_0 : 两分类变量相互独立。

H_1 : 两分类变量不是相互独立。

“独立”是一个专业术语，是没有关联的意思。

χ^2 检验统计量服从卡方分布

如果检验统计量大于临界值 ($\chi^2 > \chi^2_\alpha$)，拒绝 H_0 ，否则则不能拒绝 H_0



卡方检验介绍

卡方检验的适用条件

使用卡方检定需要注意：

- 1、少于20%的期望频数小于5
- 2、每一格期望频数大于等于1

方可使用

例题

性别与电脑类型

性别	电脑类型		
	Mac	Windows	
女性	观察频数 = 12 期望频数 = 14.4	观察频数= 108 期望频数 = 105.6	120
男性	观察频数= 24 期望频数 = 21.6	观察频数= 156 期望频数 = 158.4	180
	36	264	300

$$\begin{aligned}\chi^2 &= \sum \frac{(f_o - f_e)^2}{f_e} \\ &= \frac{(12 - 14.4)^2}{14.4} + \frac{(108 - 105.6)^2}{105.6} + \frac{(24 - 21.6)^2}{21.6} + \frac{(156 - 158.4)^2}{158.4} = 0.7576\end{aligned}$$


例题

H_0 : 性别与使用电脑系统两变量相互独立。

H_1 : 性别与使用电脑系统两变量不是相互独立。

检验统计量 $\chi^2 = 0.7576$; 临界值为 $\chi^2_{0.05} = 3.841$

自由度 $df = (R - 1)(C - 1) = (2-1)(2-1) = 1$



$\chi^2 = 0.7576 < \chi^2_{0.05} = 3.841$,
因此不能拒绝 H_0 ，因此在 $\alpha = 0.05$ 的水平下我们不能认为性别与使用的电脑类型存在相关

软件实操

- 如果使用Excel做卡方检验，需要手动整理观察频数表和期望频数表，然后使用函数**CHISQ.TEST**计算卡方检验的p值。
- 语法：**CHISQ.TEST(观测频数表范围, 期望频数表范围)**
- 结果解读：
 - p值较小（通常 < 0.05 ）：意味着观测到的数据与期望值有显著差异，可以拒绝原假设，说明变量之间存在**关联**。
 - p值较大：意味着观测值与期望值的差异不大，不能拒绝原假设，说明变量之间**无显著关联**。

软件实操

观察频数表

	Mac	Windows	总计	
女性	12	108	120	行总和 (CT)
男性	24	156	180	行总和 (CT)
总计	36	264	300	
	列总和 (RT)	列总和 (RT)		样本量 (n)

卡方检验

卡方检验的p值：
0.384088249 =CHISQ.TEST(B25:C26,K25:L26)

$p < 0.05 \rightarrow$ 有显著关联
 $p > 0.05 \rightarrow$ 无显著关联

期望频数表

	Mac	Windows
女性	14.4	105.6
男性	21.6	158.4


$$f_e = \frac{RT \times CT}{n}$$

软件实操


对于两个分类型变量关系的可视化，我们可以选用柱状图




簇状柱状图



堆叠柱状图



百分比堆积柱状图



练习

性别与存活状况

1912年4月15日，豪华巨轮泰坦尼克号与冰山相撞沉没。当时船上共有2208人，其中男性1738人，女性470人。海难发生后，幸存者为718人，其中男性374人，女性344人，以 $\alpha=0.05$ 的显著性水平检验存活状况与性别是否有关。



参考资料

- [Lizongzhang的个人空间-合集 ·Excel 数据分析实战](#)
- 《Data Visualization in Excel》(Jonathan Schwabish)

谢谢！